Сбор данных котировок и новостей

Источники: MOEX ISS (котировки, часовые свечи), Интерфакс (новости).

Данные собирались для 44 тикеров (нефтегаз, добыча, металлургия, удобрения, энергетика и акции, входящие в текущий индекс мосбиржи).

Данные собраны за период: 2020-01-01 – 2026-10-23

Данные по акциям собраны в виде почасовых свечей.

Новости собирались в виде заголовков за указанный период, далее заголовки фильтровались по ключевым словам, связанным с рассматриваемыми отраслями или компаниями, и собирались уже полные тексты отфильтрованных новостей. Отдельно собраны файлы с новостями по дням и общий файл со всеми новостями за период

Котировки акций: проверка качества и EDA

Описательная статистика

Данные проверены на пропуски и дубли, таковые найдены не были.

Рассмотрены числовые признаки котировок

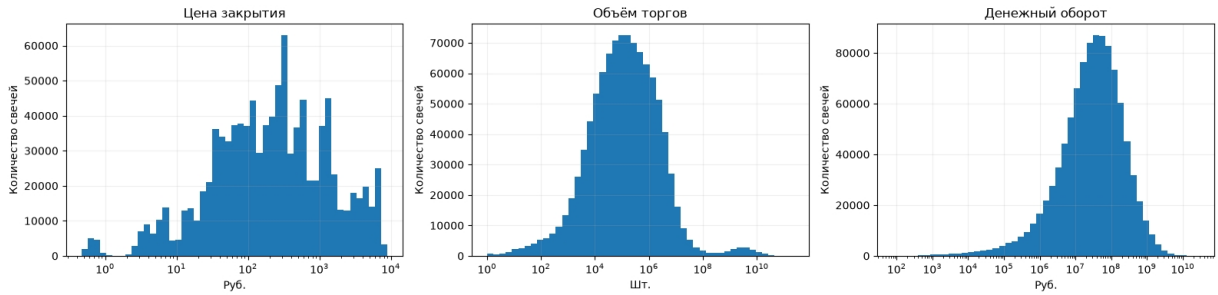


Рисунок 1. Распределение цены закрытия, объёма торгов и денежного оборота.

Обнаружено:

- минимальные цены акций – 0.46 руб.
- были несколько случаев с минимальным объемом в 1 акцию
- была обнаружена большая разница между средними и медианами для объемов и оборота и выделяющиеся максимумы

Эти экстримальные значения были отдельно проверены:

- минимальные цены акций были проверены и оказались вполне нормальными для некоторых тикеров
- минимальный объем в 1 акцию тоже не является ошибкой и является следствием низкой активности
- максимальный оборот в 28.6 млрд был найден и подтвержден для Сбера 21 февраля 2022 года, что тоже выглядит правдоподобно
- Отдельно пришлось рассмотреть всплески по выбивающимся объемам торгов для некоторых компаний

Согласованность цен и объемов торгов

В ходе первичного анализа всех 1 006 013 часовых свечей были обнаружены около 87 тысяч свечей, у которых отношение денежного оборота (value) к количественному объему (volume) отличалось от low-high цен свечей на более чем 1%

Большая доля отклонений пришлась на тикеры VTBR, T, PLZL, GMKN, TRNFP. Для них отклонение объясняется корпоративными решениями по консолидации (в случае с ВТБ) или дроблению акций (для остальных)

После корректировки количество отклонений упало до 57, около (0,0057%), но причина отклонений не выяснена.

В дальнейшем для EDA использовался скорректированный фрейм, свечи с невыясненной причиной отклонений были помечены.

Пропуски и временные разрывы

Были проверены разрывы между свечами, в том числе не подпадающие под обычне перерывы торгов (ночные, выходные, праздничные)

Итого было найдено всего 68909 разрыва. Из них всего 818 имели разрыв более трех дней.

Разрывы в 4-7 дней вероятно объясняются длинными выходными и праздниками

Разрывы в 26-33 дней приходятся на февраль-март 2022, когда останавливали торги и после восстанавливали поэтапно.

Отдельно выделяются:

- VKCO, 2023 год: редомициляция компании.
- T, 2024 год: редомициляция TCS Group.
- UGLD, июль 2025 года: приостановка торгов с 4 по 14 июля по предписанию Банка России.
- OZON, 2025 год: редомициляция и конвертация депозитарных расписок в акции, перерыв 50 дней.

Часовые доходности

Для всех акций рассчитана доходность относительно предыдущей свечи этой же акции.

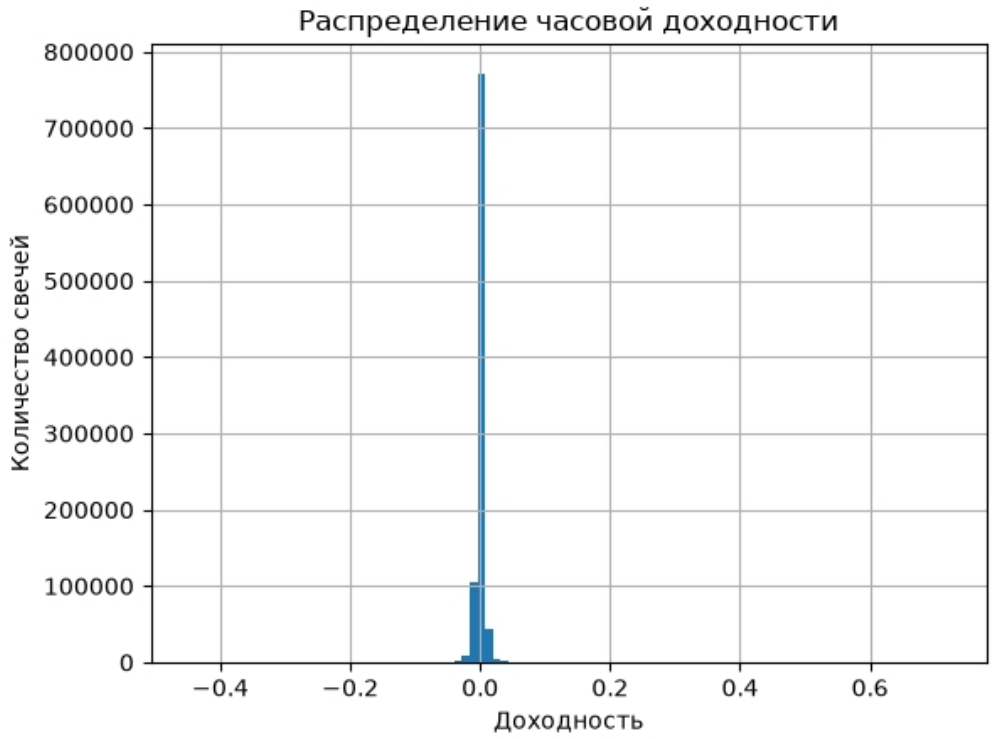


Рисунок 2. Распределение часовой доходности.

Видим что распределение часовой доходности в основном находится около нуля.

Описательная статистика доходности по тикерам

Были посчитаны для всех акций:

- count — сколько часовых доходностей рассчитано.
- mean — средняя часовая доходность в процентах.
- std — стандартное отклонение доходностей, простая мера часовой волатильности.
- min, max — самые сильные падения и роста за один час.
- median — медианная часовая доходность.

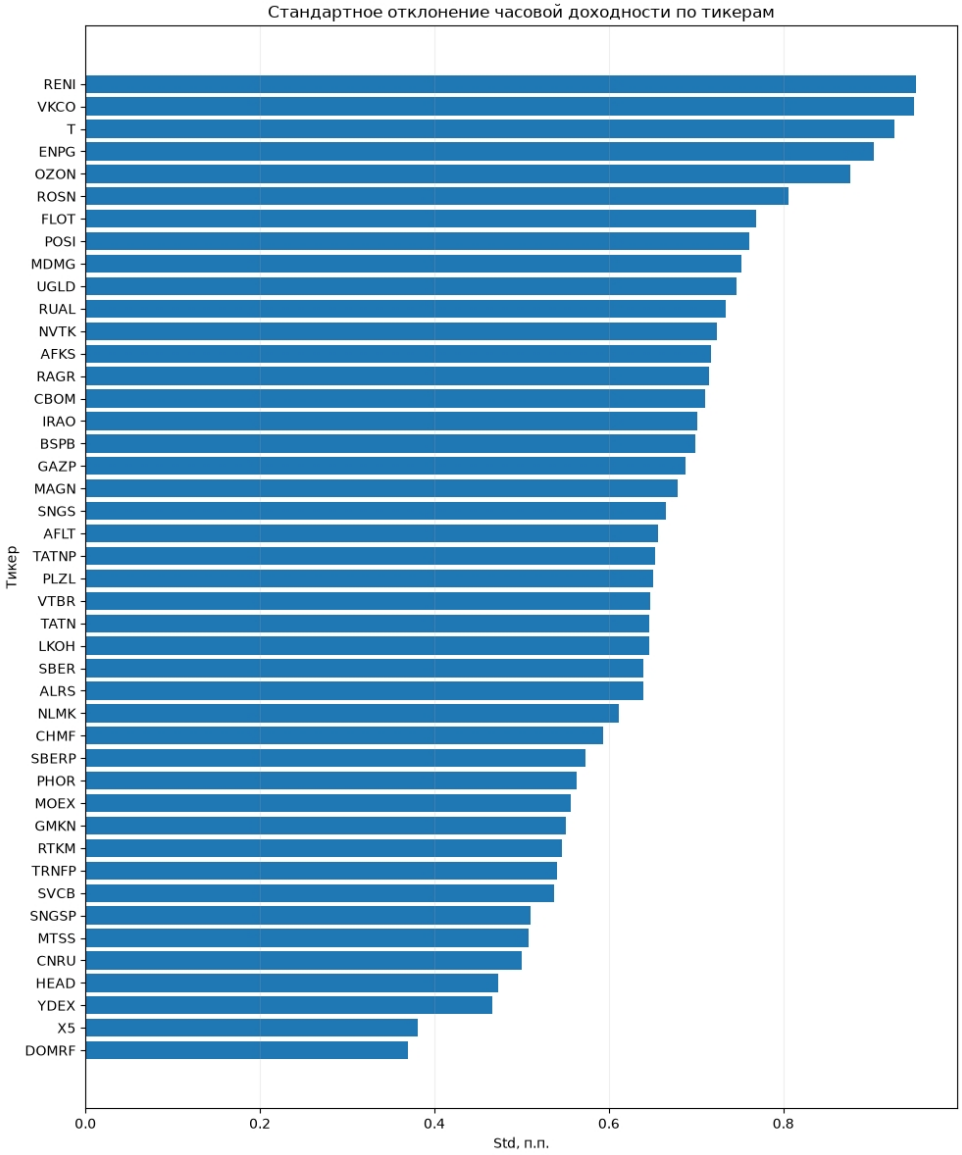


Рисунок 3. Стандартное отклонение часовой доходности по тикерам.

Самые волатильные акции: RENI, VKCO, T, ENPG

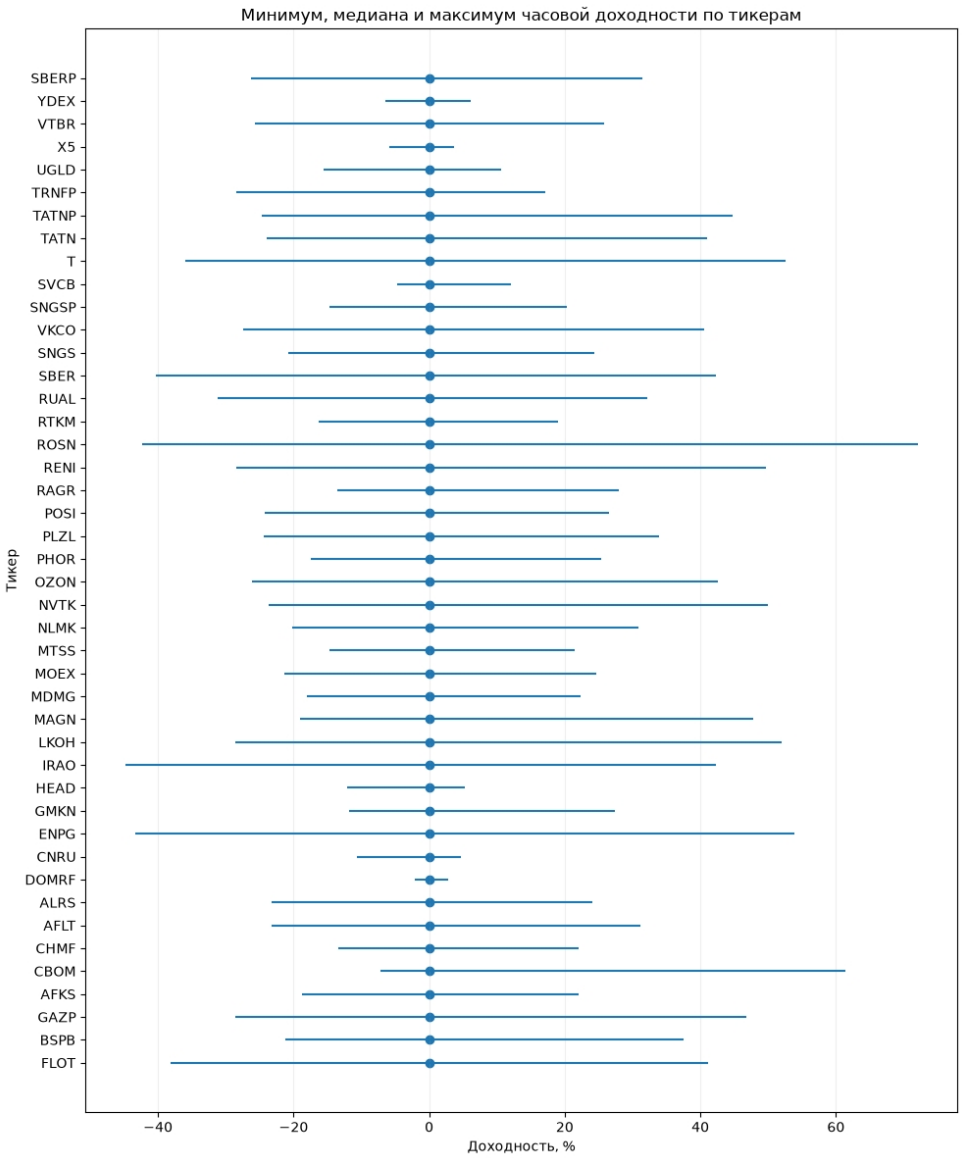


Рисунок 4. Минимальная, медианная и максимальная часовая доходность по тикерам.

Минимальные и максимальные доходности некоторых акций достигают десятков процентов

Отдельно были рассмотрены доходности через торговые перерыва

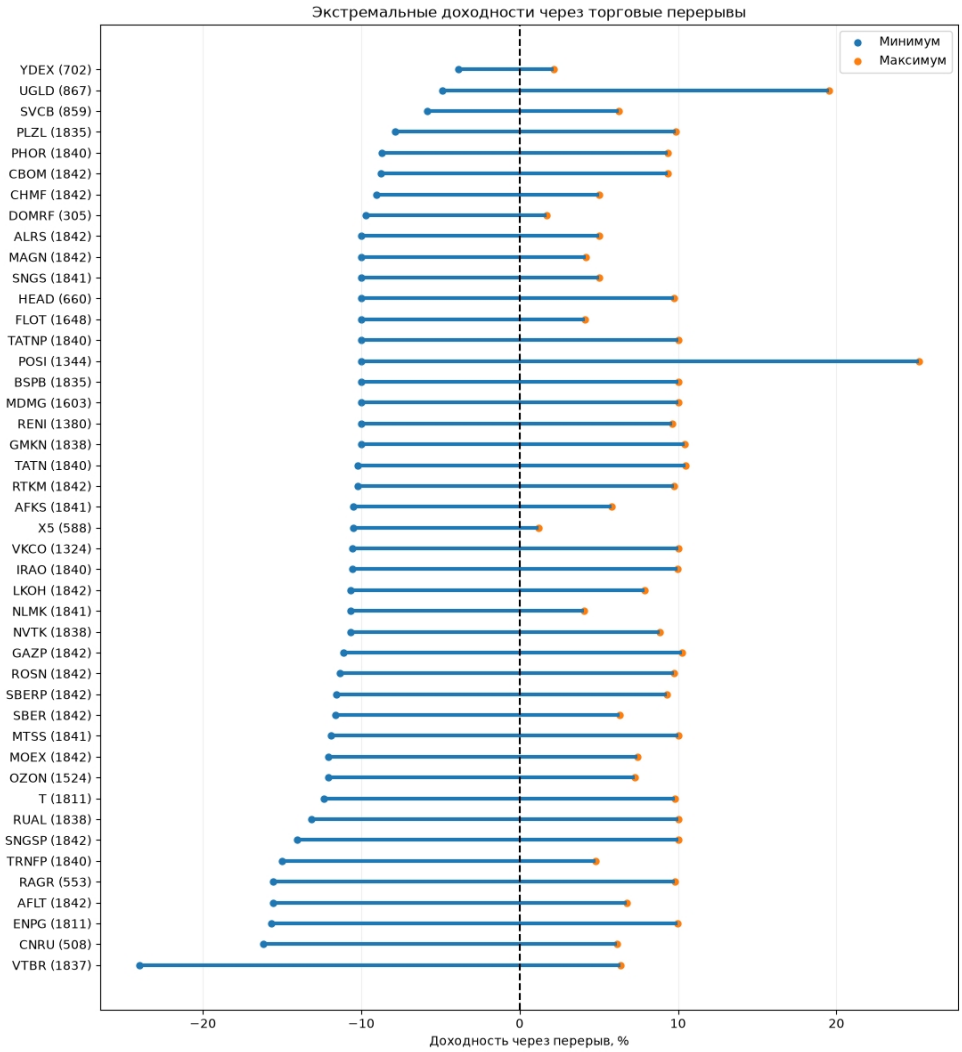


Рисунок 5. Экстремальные доходности через торговые перерывы.

Видим, что для некоторых компаний экстремумы довольно большие. Однако учитывая что и часовые доходности достаточно большие, следует в дальнейшем учитывать все.

Отдельно проверены экстремумы и на какие даты они пришлись для каких компаний:

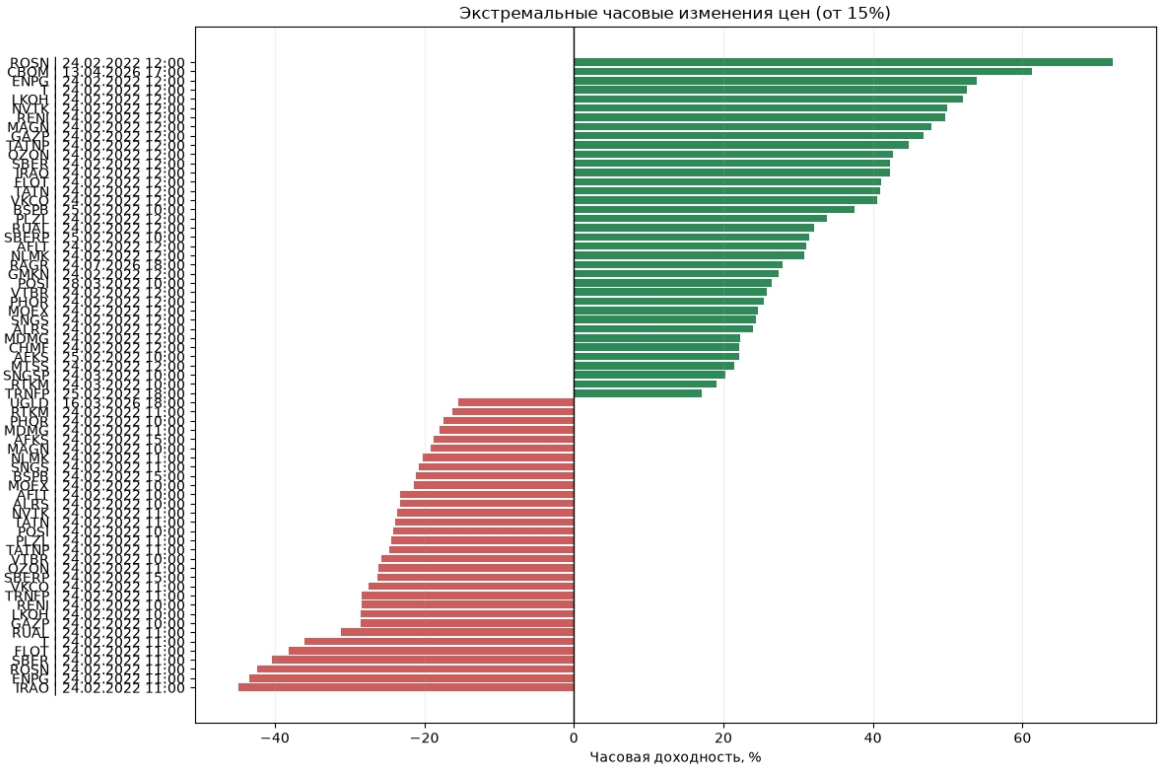


Рисунок 6. Экстремальные часовые изменения цен от 15%.

БОльшая часть ожидаемо выпала на февраль 2022 года. Но есть и исключения, были проверены отдельно, они объясняются следующими событиями:

- CBOM - решение о реструктуризации банка и возможном выкупе акций
- RAGR - объявление о крупных дивидендах
- UGLD - арест денег компании

Денежные обороты торгов

Рассчитана статистика торговых оборотов:

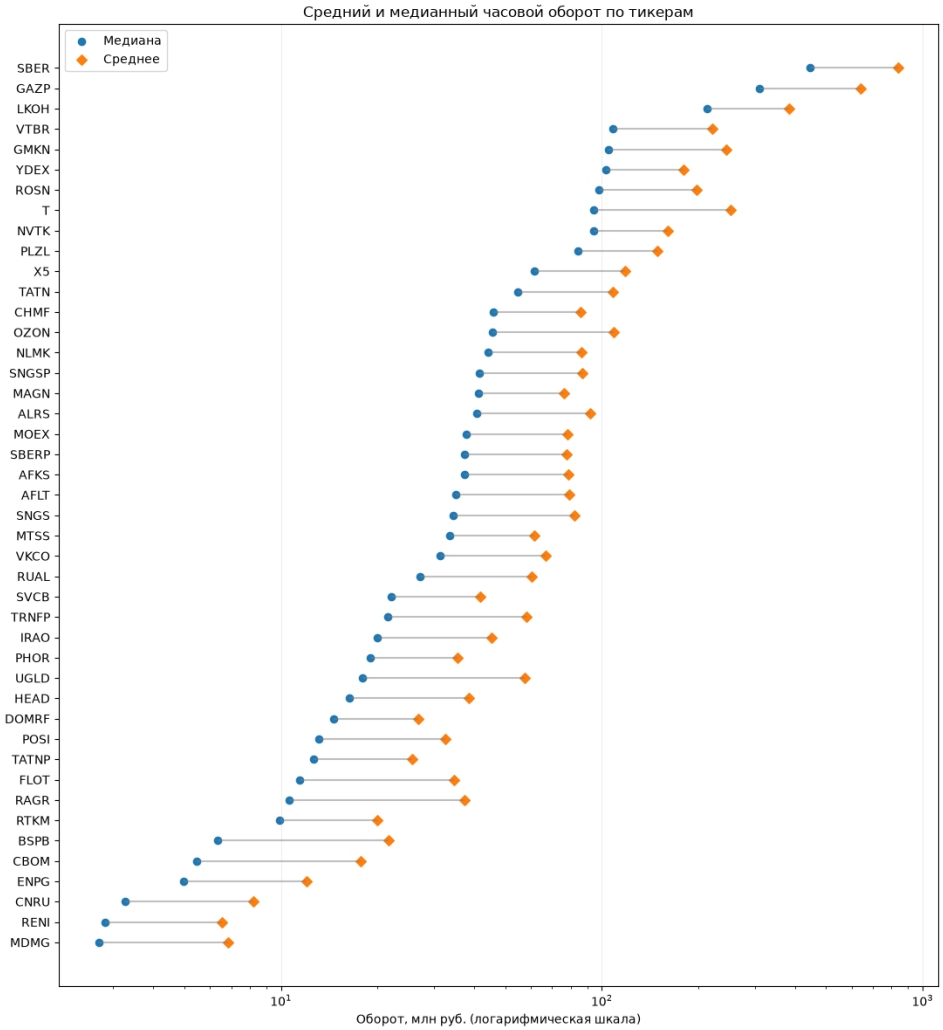


Рисунок 7. Средний и медианный часовой оборот по тикерам.

1. у большинства акций средний оборот значительно превышает медианный, что говорит о наличии некоторых периодов очень сильной торговой активности
2. есть существенные различия по побороту между акциями. Это видится нормальным: условные Сбер и Лукойл торгуются плотнее, чем условный MDMG

EDA новостей интерфакса

Тематическое распределение

Провели анализ распределения отобранных новостей, получили:

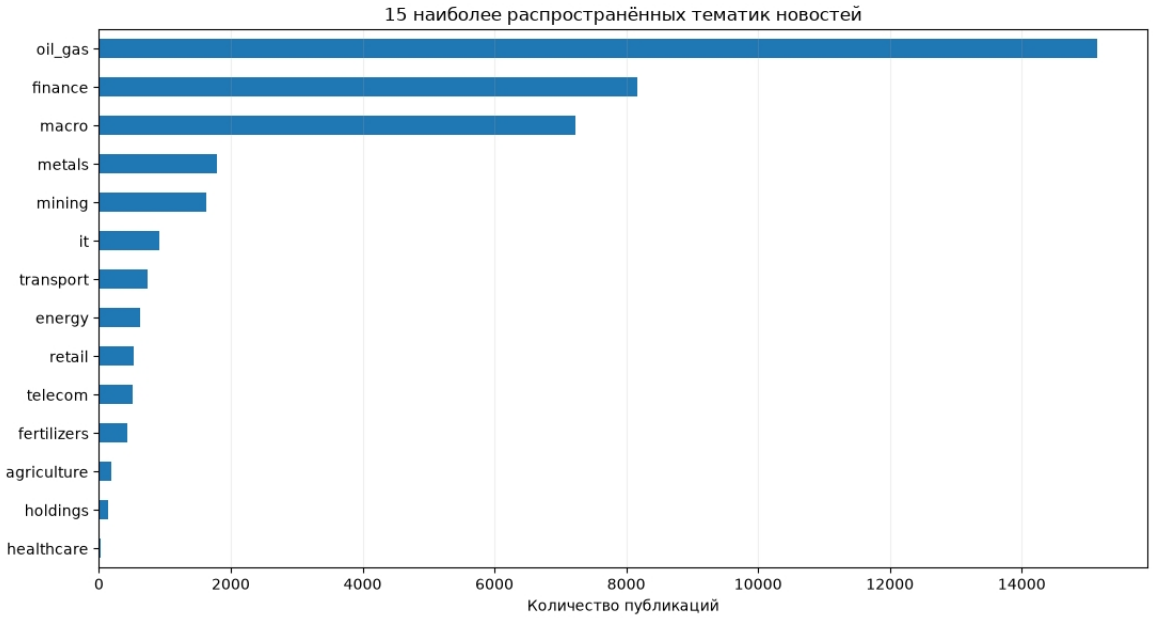


Рисунок 8. Наиболее распространённые тематики новостей.

Преобладают новости нефтегазовой, общефинансовой и макроэкономической тематик

Распределение во времени

Также была рассмотрена динамика распределения новостей во времени.



Рисунок 9. Динамика числа публикаций по месяцам.

Ожидаемо, пик новостей приходится на февраль-март 22-года и дальше в целом количество новостей большее чем до этого.

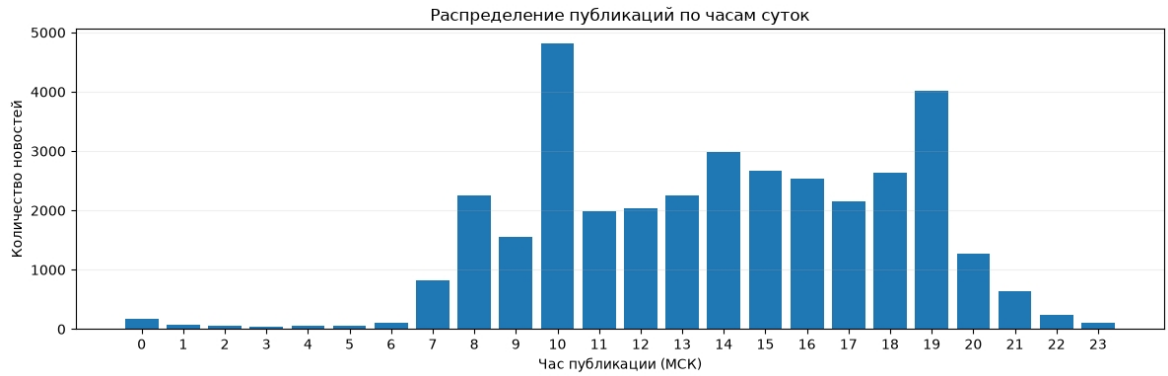


Рисунок 10. Распределение публикаций по часам суток.

Распределение новостей по часам показывает, что в течение дня значительно больше новостей в 10 утра и 19 вечера.

Длина заголовков и текстов

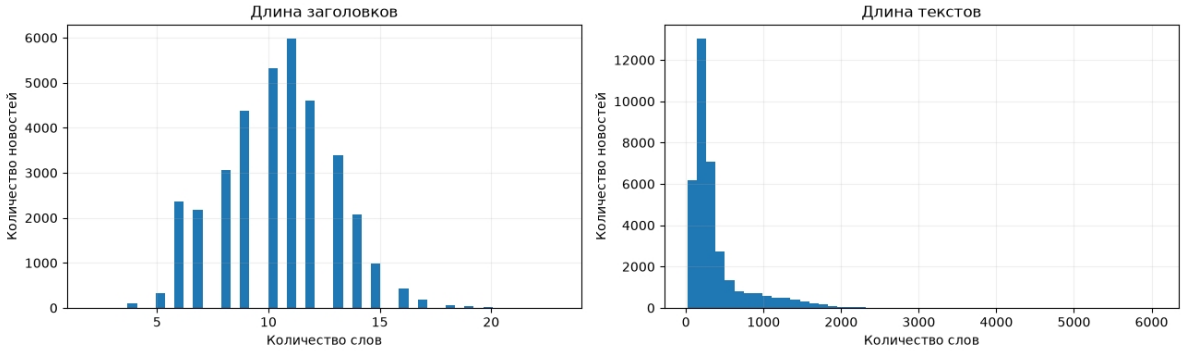


Рисунок 11. Распределение длины заголовков и полных текстов.

Выявлено, что есть отдельные новости с выделяющимся количеством слов в тексте. Проверка показала что в основном это Заявления ЦБ РФ и аналитические работы.

Предобработка текстов

В качестве предобработки были проведены токенизация, лемматизация, удалены стоп-слова

Частотный анализ

Проведен частотный анализ слов

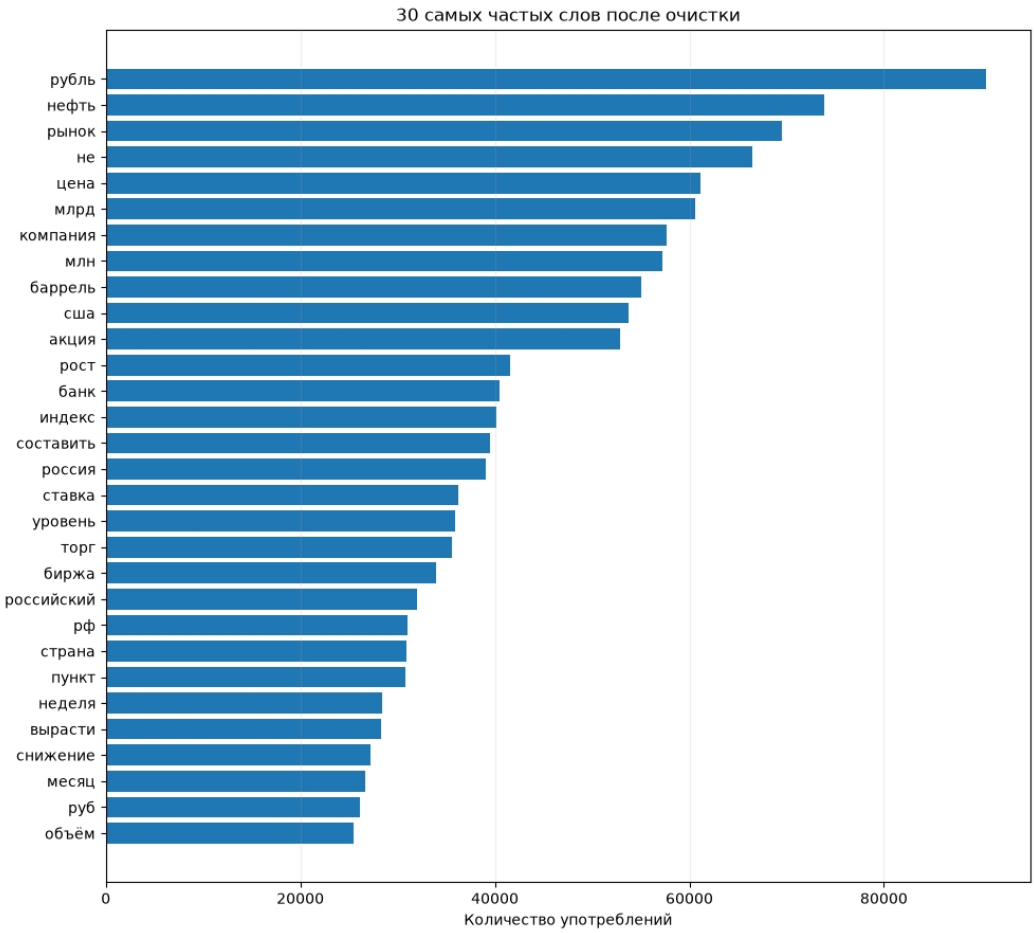


Рисунок 12. Наиболее частые слова после очистки.

Видим, что преобладают слова экономической тематики, что соответствует методу отбора новостей. Явно выделяются слова нефтегазовой тематики, что тоже объяснимо.

Очень много "не"

Также много слов общей и общефинансовой тматики - млрд, руб, объем и тд

Биграммы

Были рассмотрены сочетания слов. Сочетания слов брались из заголовков, так как количество текста меньшее по сравнению со всем текстом новости, а суть публикации заголовки передают точно.

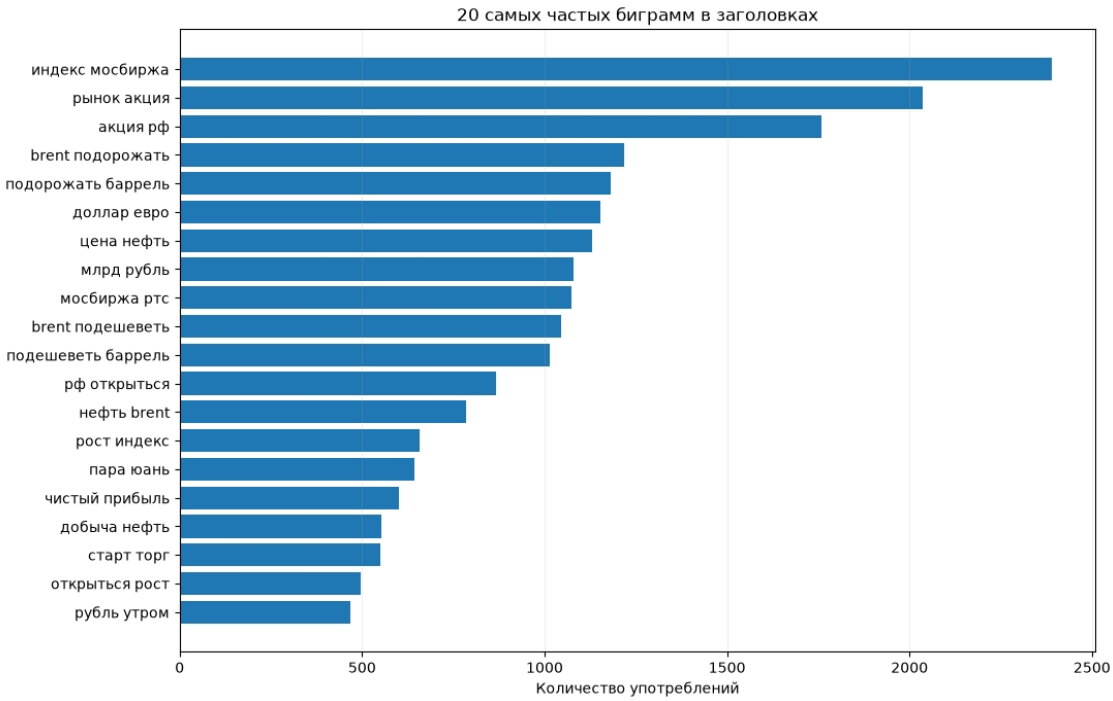


Рисунок 13. Наиболее частые биграммы заголовков.

Биграммы вышли вполне осмысленные, все на экономическую тематику. Преобладают общие финансовые новости. Также очень много нефтяной тематики.

Числовое представление текстов

Для 5000 самых популярных слов был составлен Bag Of Words. Для самой первой статьи корпуса следующий пример:

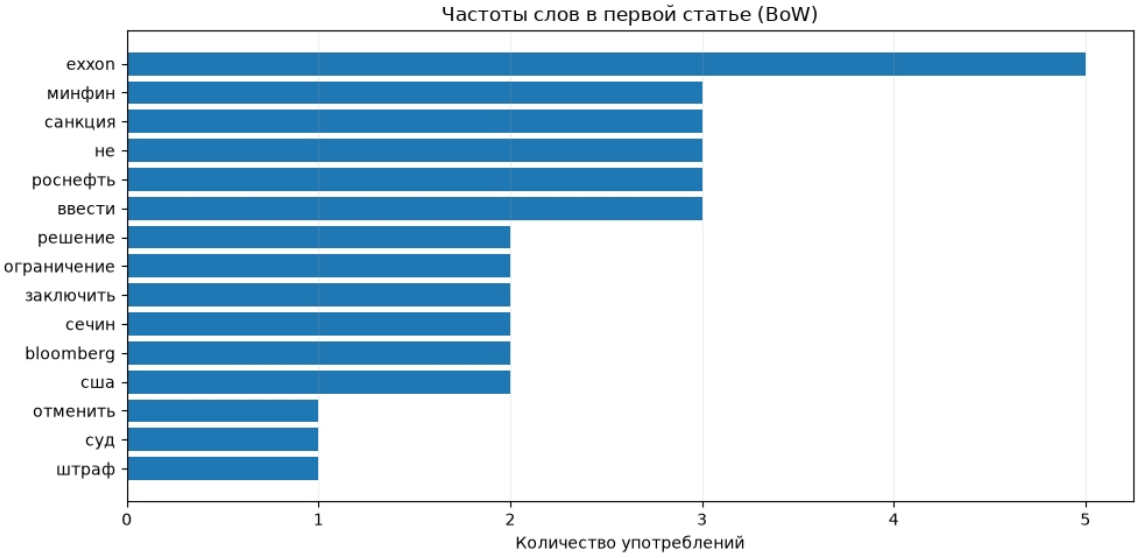


Рисунок 14. Частоты слов первой статьи в представлении BoW.

Также составлен TF-IDF. Также для первой статьи корпуса:

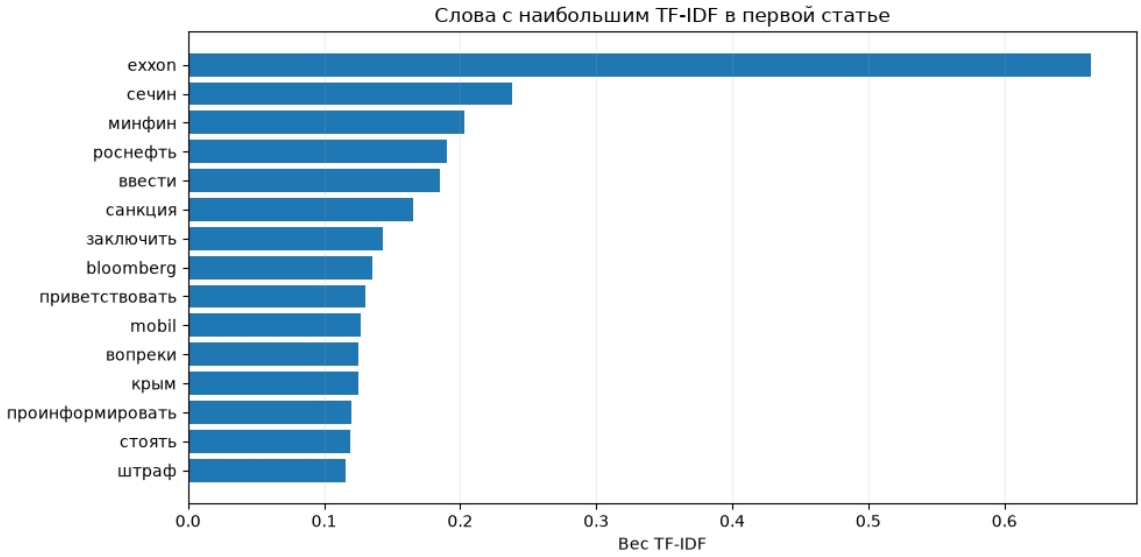


Рисунок 15. Слова с наибольшим весом TF-IDF в первой статье.

Совместный EDA котировок и новостей

Подготовка

Данные котировок и новостей были загружены с указанными в соответствующих разделах корректировками.

Новости и свечи были сопоставлены по приниципу, что находится новость с заголовком, связанным по смыслу с тикером, к ней находится ближайшая по времени свеча.

Свечи были проанализированы на разрывы в торгах, выявлено что подавляющая часть торгов приходится на непрерывные.

Доходность

Изменения доходности после новостей были оценены на разных горизонтах – час после новости, 3 час и 8.

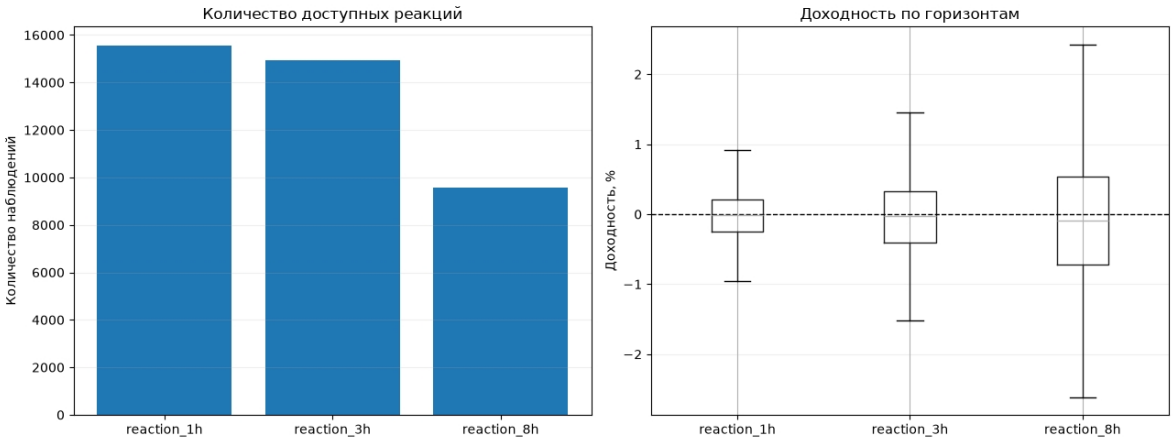


Рисунок 16. Число доступных наблюдений и распределение доходностей по горизонтам.

Отметим, что заметно увеличение изменения доходности на горизонте 8 часов, но тут возможно что увеличение могло быть связано с ростом фоновой доходности. Коме того, выборка для 8 часового горизонта меньше.

Предварительно оценили баланс классов. Как классы были отобраны направления изменения напрвления доходности после новостей:



Рисунок 17. Баланс классов по направлению трёхчасовой доходности.

Видимо, что сильного дисбаланса нет, класс без изменения встречается очень редко.

Также были проверены корреляции числовых признаков новостей с доходностью:



Рисунок 18. Корреляции числовых признаков с трёхчасовой доходностью.

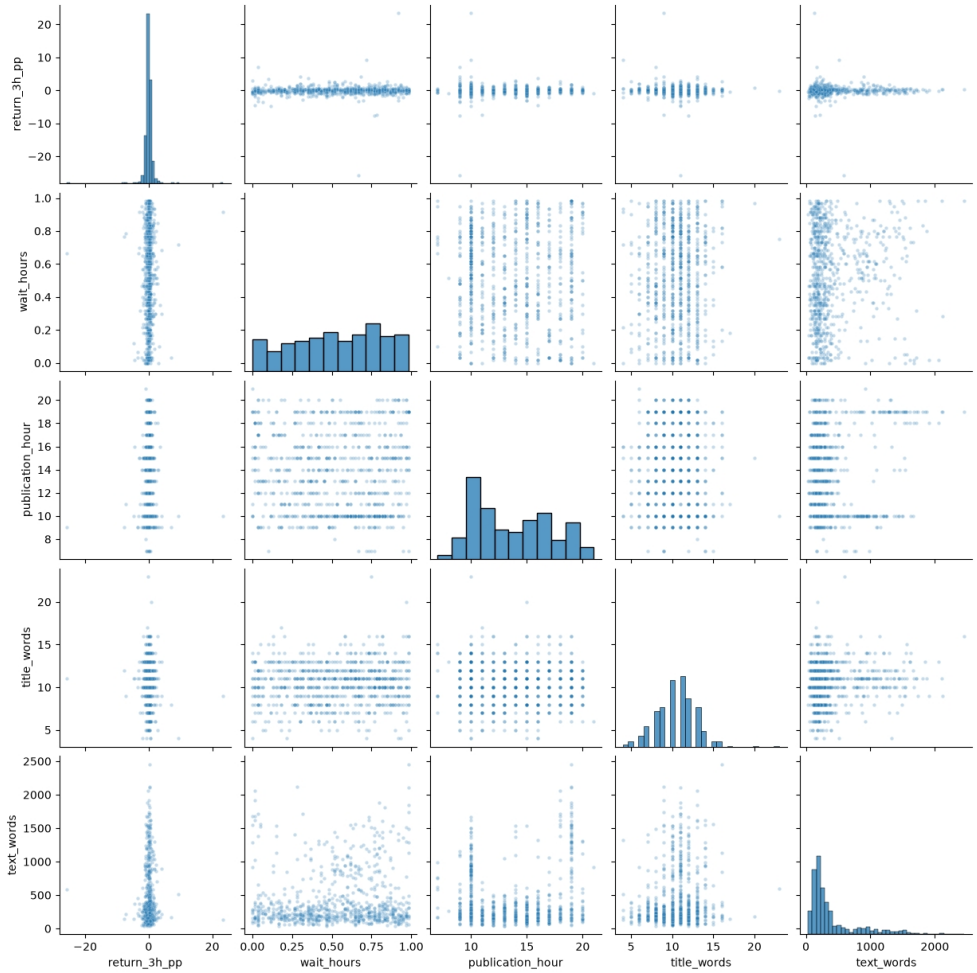


Рисунок 19. Попарные распределения числовых признаков на подвыборке.

Корреляции практически отсутствуют.

Оценили изменение доходности после новости с фоновыми изменениями.

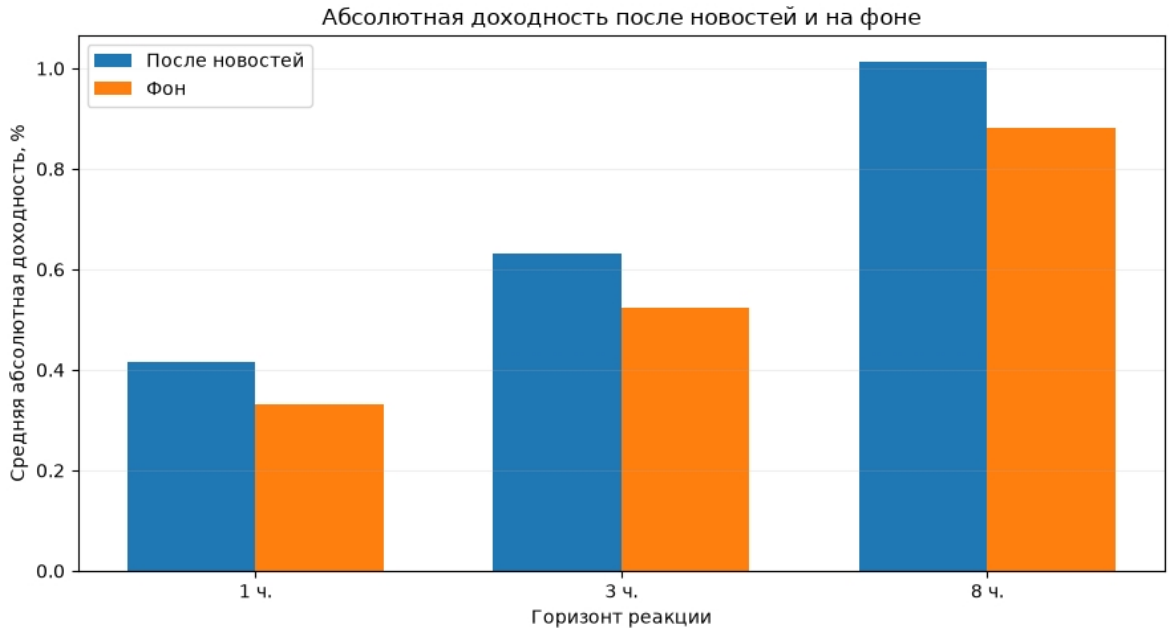


Рисунок 20. Средняя абсолютная доходность после новостей и на фоне.

Также оценено изменение разрыва между доходностью после новости и фоновым изменением в течение времени после новости:

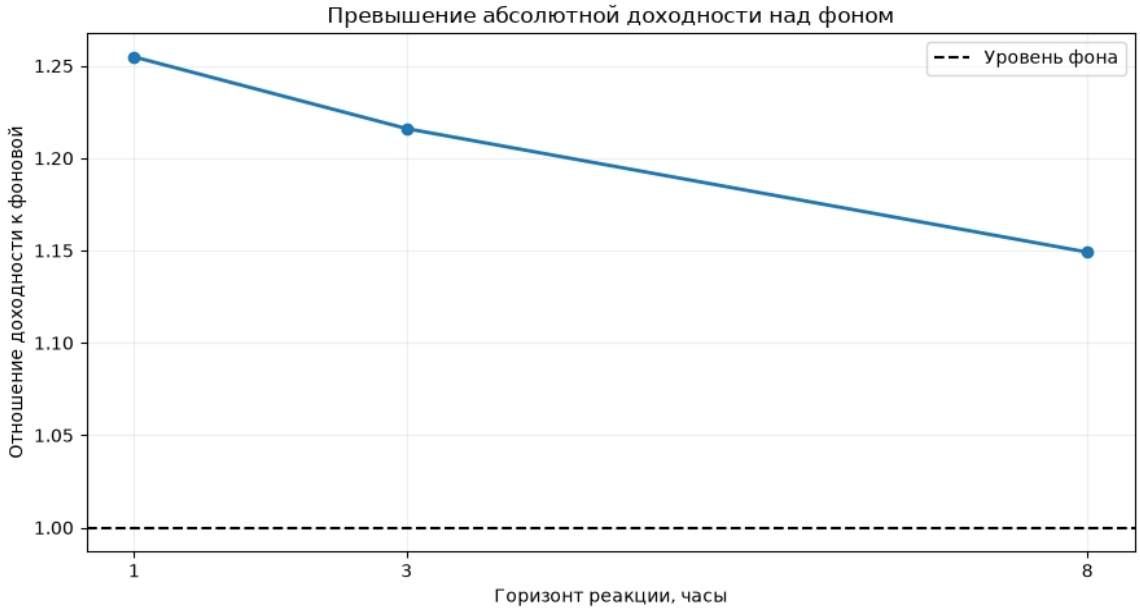


Рисунок 21. Отношение абсолютной доходности к фону на одинаковой выборке.

Выявлено, что чем больше времени с новости, тем меньше изменение доходности по сравнению с фоном.

Также проверено, насколько часто возникают всплески доходности после новостей по сравнению с фоновой доходностью.

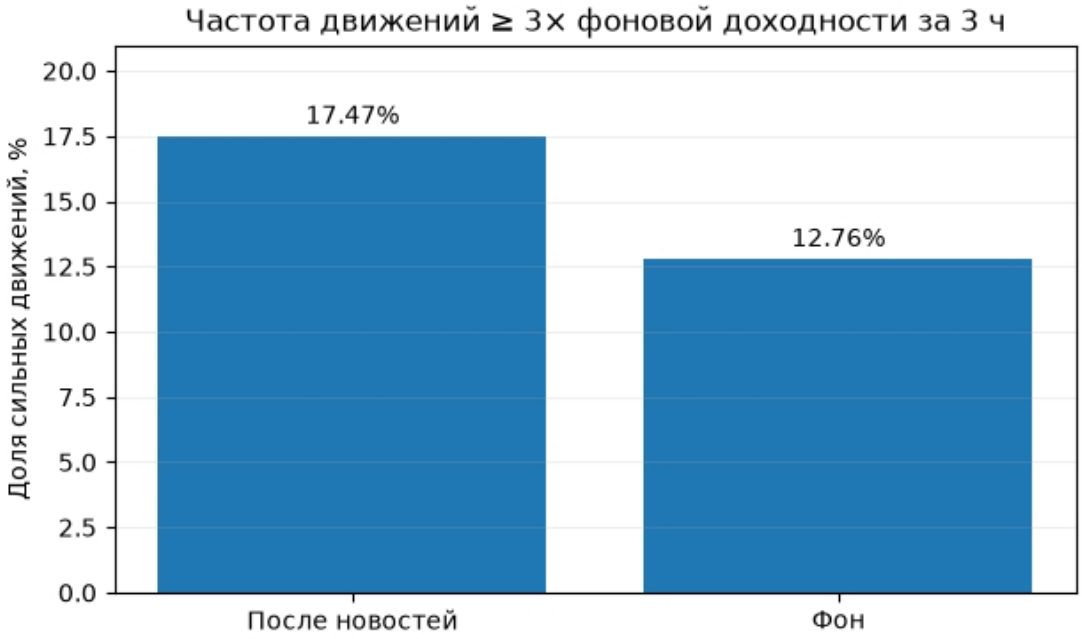


Рисунок 22. Частота сильных движений трёхчасовой доходности.

Видим разницу в 5%.

Оборот торгов

Похожим образом сравниваем изменение оборота торгов после новости по сравнению с фоновыми изменениями.



Рисунок 23. Распределение оборота относительно фона после новостей.

По графику видно что для достаточно большого количества наблюдений увеличение оборота относительно фона довольно высокое. В цифрах:

Оборот ≥ 2х фонового: 34.6%

Оборот ≥ 3х фонового: 22.5%

Оборот ≥ 5х фонового: 12.9%

Оборот ≥ 10х фонового: 5.8%

Исходя из того, что могут быть всплески как после связанных новостей, так и без каких-либо новостей, провели сравнение всплесков в несколько раз после новости с подобными всплесками для обычных свечей:

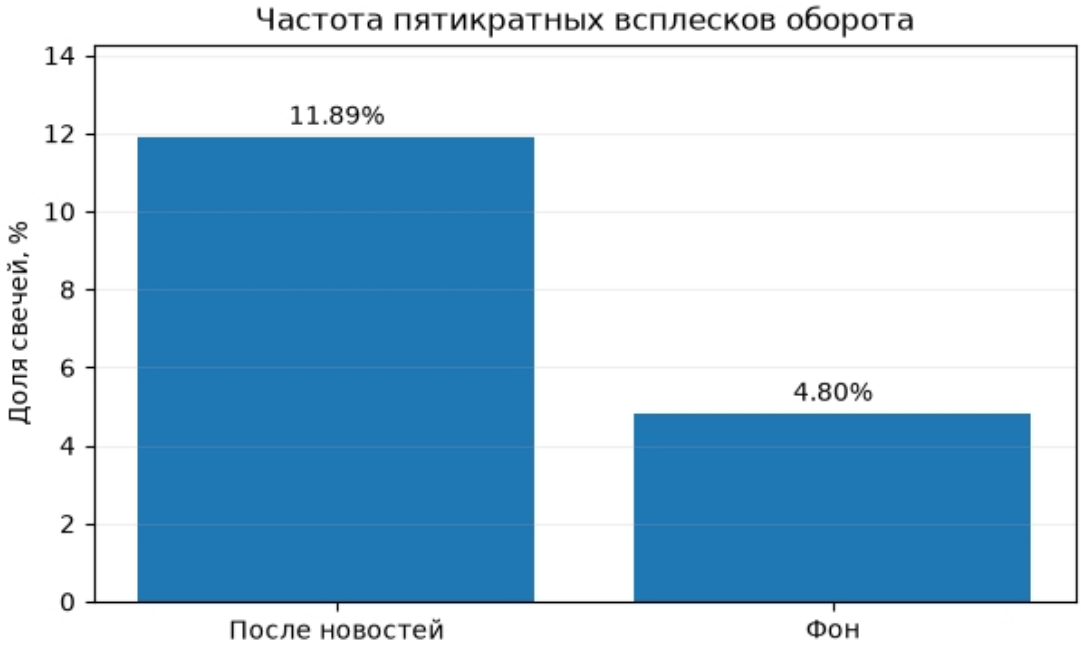


Рисунок 24. Частота пятикратных всплесков оборота после новостей и на фоне.

Пятикратный всплеск после новости встречается значительно чаще чем подобный всплеск без нее.

Биграммы и рыночные показатели

Проанализировали связь между биграммами новостей и изменения доходности. Оцениваем для всех акций вообще и для сравнения для отдельных тикеров. На графике пример для Сбера:

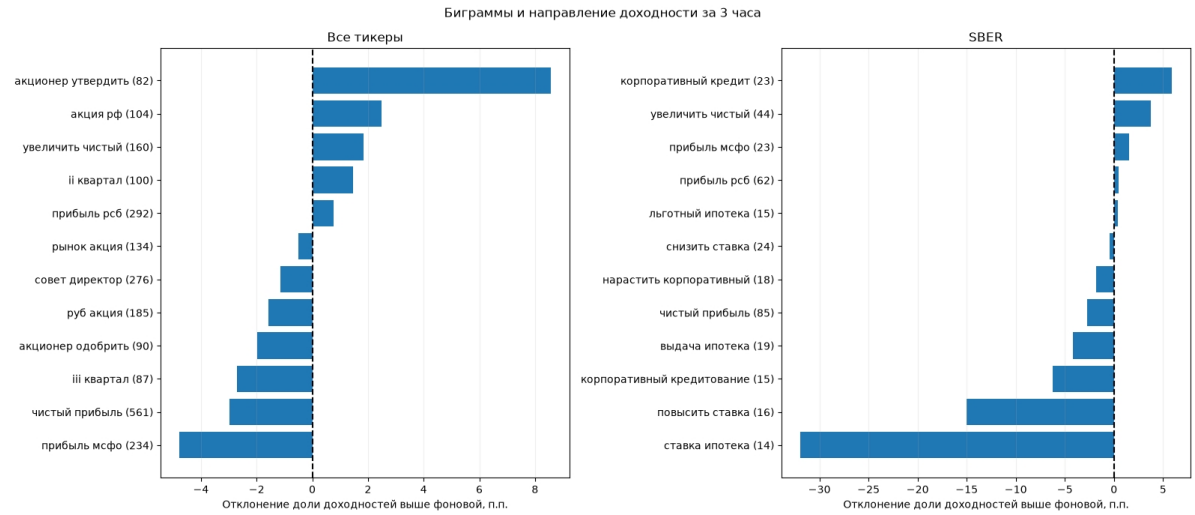


Рисунок 25. Биграммы и направление доходности: все тикеры и SBER.

И аналогично для изменений торгового оборота:

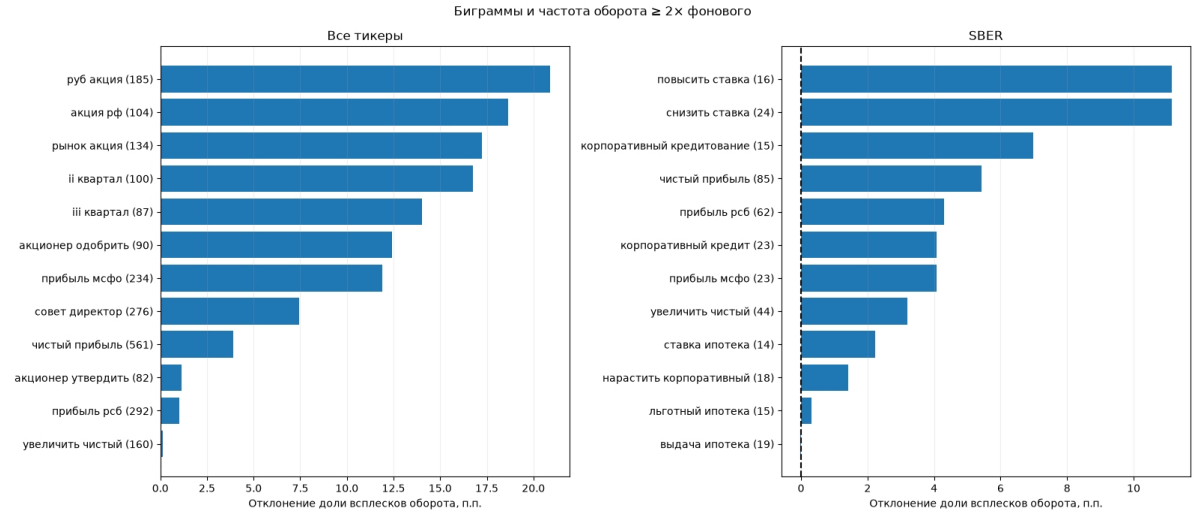


Рисунок 26. Биграммы и всплески оборота: все тикеры и SBER.